Web Mining
Laboratoire 3

Elena Najdenovska et Cédric Campos Carvalho

Institut des Technologies de l'Information et de la Communication (IICT)

Application de techniques de Data Mining en utilisant le logiciel *RapidMiner*

Les points étudiés:

- Prise en main de *RapidMiner*
- Modélisation d'un filtre des « pièges-à-clics »
- Analyse des sentiment sur des commentaires à l'aide de *WordNet*
- Recommandation de films
- Règles d'association sur des achats d'un site de vente en ligne
- Clustering d'applications Google

- A rendre sur *Moodle* avant le **jeudi 25.04.2024 à 23h59**
- Groupes de 3 personnes

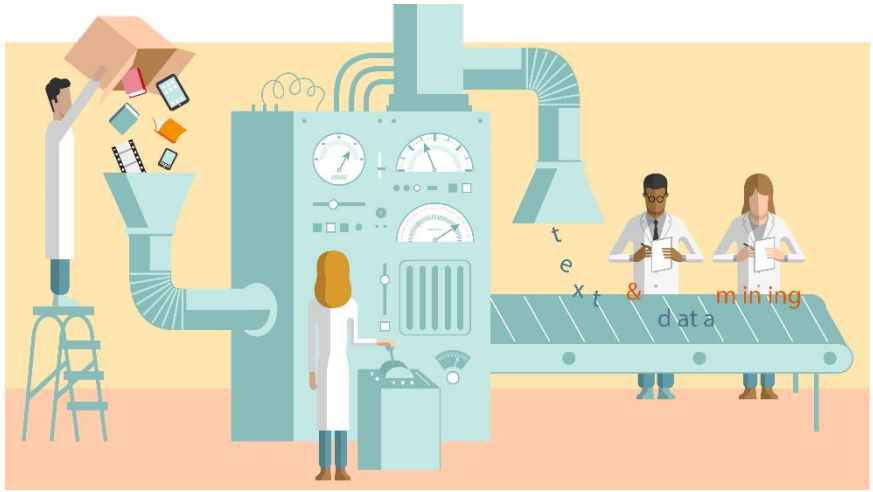

RapidMiner

- Plateforme logicielle de traitement, de modélisation et d'analyse de données
  - Prétraitement
  - Application d'algorithmes et techniques de data mining
  - Evaluation

- Version communautaire gratuite mais limitée
- Version professionnelle payante
- ✓Version académique gratuite et non limitée pendant 1 an

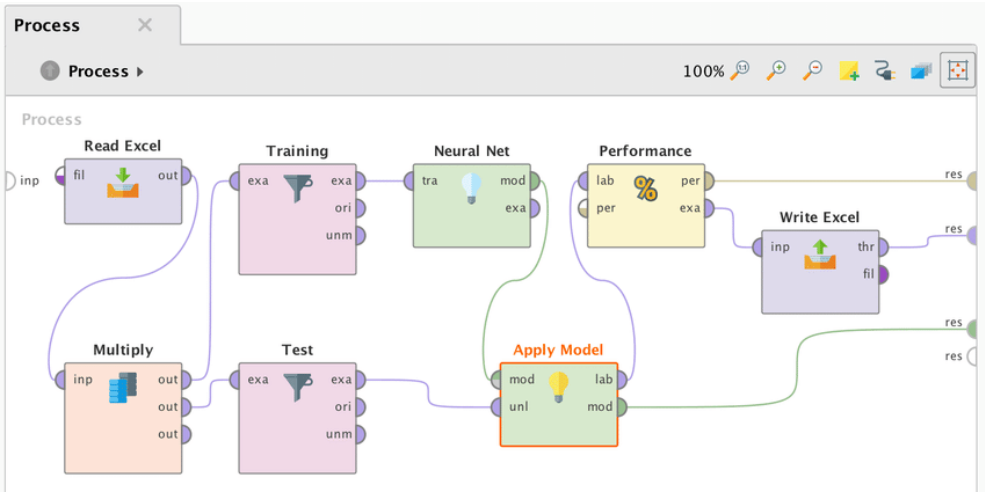

Partie 1
Filtre des « pièges-à-clics »

- Prise en main guidée de *RapidMiner*
- Filtrage des 10'000 titres des médias d'information en ligne
- Séparation du jeu de données: *ensemble d'apprentissage* et *ensemble de test*
- Construction d'un modèle par apprentissage supervisé, puis évaluation de celui-ci
- Quelques questions

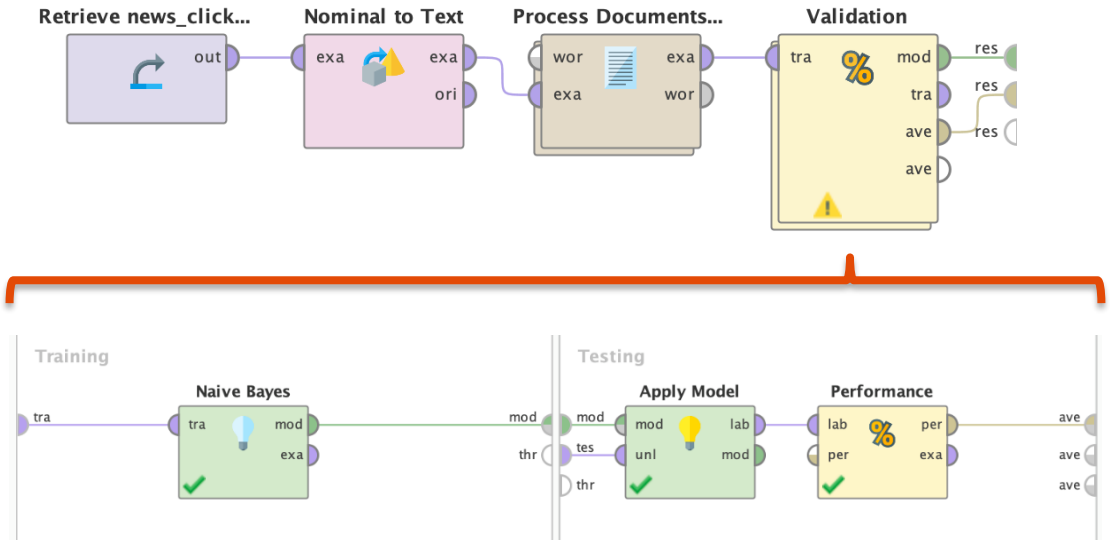

Partie 2
Analyse des sentiments

- *WordNet* https://wordnet.princeton.edu/
- Base de données lexicale composée de noms, de verbes, d'adjectifs et d'adverbes en anglais groupés dans des ensembles de synonymes (synsets)
- L'extension de *RapidMiner* permet de d'associer une valeur numérique correspondant au sentiment par rapport à des données textuelles:
  <0 sentiment négatif et >0 positif
- On va utiliser un ensemble d'environ 3'000 commentaires d'internautes issus de *Twitter liés au sujet COVID-19* .
  Ceux-ci sont déjà étiquetés
- Vous devrez faire une petite analyse comparant les sentiments issus du module *Wordnet* et ceux des étiquettes

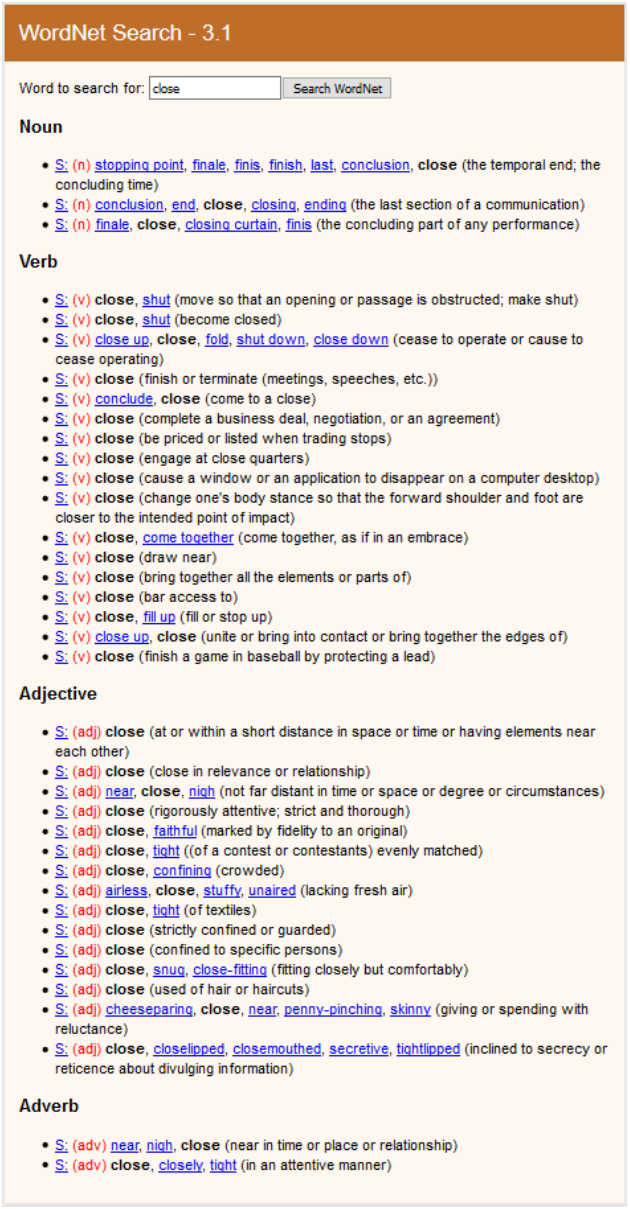

WordNet Search - 3.1

Word to search for: close Search WordNet

Noun

- S: (n) stopping point, finale, finis, finish, last, conclusion, **close** (the temporal end; the concluding time)
- S: (n) conclusion, end, **close**, closing, ending (the last section of a communication)
- S: (n) finale, **close**, closing curtain, finis (the concluding part of any performance)

Verb

- S: (v) **close**, shut (move so that an opening or passage is obstructed; make shut)
- S: (v) **close**, shut (become closed)
- S: (v) close up, **close**, fold, shut down, close down (cease to operate or cause to cease operating)
- S: (v) **close** (finish or terminate (meetings, speeches, etc.))
- S: (v) conclude, **close** (come to a close)
- S: (v) **close** (complete a business deal, negotiation, or an agreement)
- S: (v) **close** (be priced or listed when trading stops)
- S: (v) **close** (engage at close quarters)
- S: (v) **close** (cause a window or an application to disappear on a computer desktop)
- S: (v) **close** (change one's body stance so that the forward shoulder and foot are closer to the intended point of impact)
- S: (v) **close**, come together (come together, as if in an embrace)
- S: (v) **close** (draw near)
- S: (v) **close** (bring together all the elements or parts of)
- S: (v) **close** (bar access to)
- S: (v) **close**, fill up (fill or stop up)
- S: (v) close up, **close** (unite or bring into contact or bring together the edges of)
- S: (v) **close** (finish a game in baseball by protecting a lead)

Adjective

- S: (adj) **close** (at or within a short distance in space or time or having elements near each other)
- S: (adj) **close** (close in relevance or relationship)
- S: (adj) near, **close**, nigh (not far distant in time or space or degree or circumstances)
- S: (adj) **close** (rigorously attentive; strict and thorough)
- S: (adj) **close**, faithful (marked by fidelity to an original)
- S: (adj) **close**, tight ((of a contest or contestants) evenly matched)
- S: (adj) **close**, confining (crowded)
- S: (adj) airless, **close**, stuffy, unaired (lacking fresh air)
- S: (adj) **close**, tight (of textiles)
- S: (adj) **close** (strictly confined or guarded)
- S: (adj) **close** (confined to specific persons)
- S: (adj) **close**, snug, close-fitting (fitting closely but comfortably)
- S: (adj) **close** (used of hair or haircuts)
- S: (adj) cheeseparing, **close**, near, penny-pinching, skinny (giving or spending with reluctance)
- S: (adj) **close**, closelipped, closemouthed, secretive, tightlipped (inclined to secrecy or reticence about divulging information)

Adverb

- S: (adv) near, nigh, **close** (near in time or place or relationship)
- S: (adv) **close**, closely, tight (in an attentive manner)

Partie 3
Système de recommandation

3 types:

- Systèmes basés sur un **filtrage collaboratif**
  - informations sociales, des préférences et des expériences d'autres utilisateurs
  - hypothèse : les utilisateurs ayant des goûts similaires pourraient apprécier et consommer des articles similaires
- Systèmes basés sur un **filtrage de contenu**
  - des informations sur les activités passées de l'utilisateur
  - hypothèse : l'utilisateur pourrait être intéressé par des éléments similaires à ceux pour lesquels un intérêt a déjà été montré
- Systèmes **hybrides**
  - combinent à la fois plusieurs approches afin de renforcer leurs avantages

Partie 3
Système de recommandation

- Approche collaborative pour la recommandation et la prédiction des notes
- Données : environ 9800 films notés par 610 utilisateurs de MovieLens
- 2 ensembles des données:
  - *movies.csv*
  - *ratings.csv*
- Prétraitement des données pour joindre les films avec les notes des utilisateurs (attribut en commun: *movieID*)
- Quelques questions

Partie 4
Market Basket Analysis

- Une technique de data mining qui permet de trouver les groupes d'articles qui ont la tendance à apparaître ensemble lors d'une transaction

- Construction du modèle basé sur des règles conditionnelles:
  - Si **condition** alors **résultat**
    - « Si un client achète du beurre, alors il achète aussi du lait »
    - « Si un client achète du lait et du sel, alors il achète aussi du fromage »

Partie 4
Market Basket Analysis

- Articles achetés sur un site web pendant 1 année

- Forme des données fournies:
  - *InvoiceNo : identifiant de la facture/ vente*
  - *StockCode : identifiant du produit*
  - *Description : produit acheté*
  - *Quantity : quantité*
  - *InvoiceDate : date de la commande/ paiement*
  - *UnitPrice : prix du produit*
  - *CustomerID: identifiant du client*
  - *Country : pays de résidence du client*

- Prétraitement des données pour organiser les achats par client

- Quelques questions

Partie 5
Clustering

- Clustering d'applications sur Google Play Store

- Différents attributs pour chaque applications
  - *Rating : l'évaluation globale de l'application par les utilisateurs*
  - *Reviews : le nombre d'avis d'utilisateurs*
  - *Size : la taille de l'application*
  - *Installs : nombre d'utilisateurs qui ont installé l'application*
  - *Price : prix de l'application*

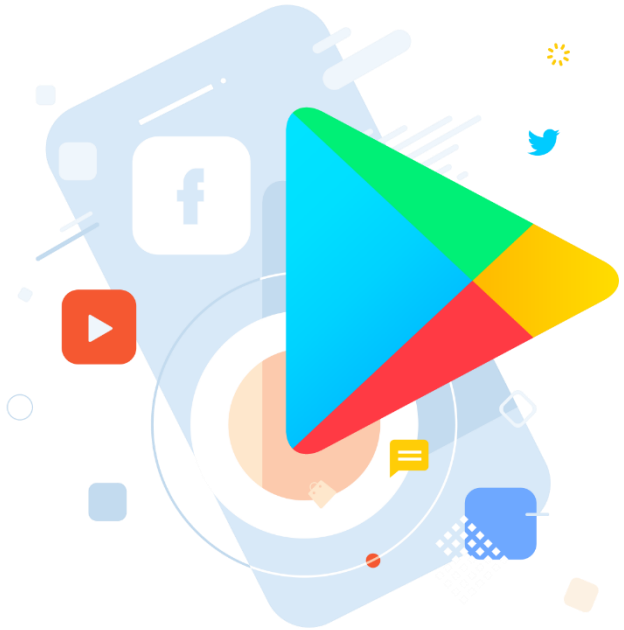

- Et pour interpréter les résultats (ne pas prendre en compte pour le clustering)
  - *App*: nom de l'application
  - *Category*: le genre

- Quelques questions

Rendu

- Sur la page *Moodle* du cours

- Une archive *zip* contenant
  - Votre rapport
  - Vos *process RapidMiner*

- Dans votre rapport, en plus des réponses aux questions posées vous discuterez du fonctionnement de votre programme et de vos choix d'implémentation